



南开大学
Nankai University

南 开 大 学

计 算 机 学 院

并行程序设计期末实验报告

基于 MPI 任务池的矩阵 SVD 算子并行化实验

姓名：邹俊轩

学号：2412592

年级：2024 级

专业：计算机科学与技术

指导教师：王刚

GitHub 仓库：[HTTPS://GITHUB.COM/POINTZU/MPI](https://github.com/POINTZU/MPI)

2026 年 6 月 9 日

摘要

本实验选择矩阵奇异值分解 (SVD) 算子作为 MPI 编程题目。将并行化集中在 Golub-Kahan (GKH) 迭代阶段: 0 号进程负责维护活动块任务池, 其余进程空闲后领取非平凡活动块, 执行一轮 bulge chasing, 并只回传对应的 B 子块以及 U, V 的相关列。实验在课程服务器上采用 `mpic++` 编译并通过 `qsub_mpi.sh` 提交, 共采集 41 组有效运行数据, 覆盖 MPI 进程数、编译优化等级、SIMD 开关和重复运行稳定性。全部原始输出均通过 5 个测试样例, 最大相对重构误差为 4.80×10^{-13} , 最大正交误差约为 2.38×10^{-13} 。

实验表明, 普通随机矩阵上的 SVD 并不随 MPI 进程数单调加速。以 GKH 阶段为例, $np = 4$ 时平均耗时从 23147.60 ms 降至 15975.63 ms, 加速比为 1.45; 继续增加到 $np = 8$ 、 $np = 16$ 后收益下降, $np = 32$ 反而退化为 0.34 倍。主要原因是 GKH 的活动块并行度不足, 且跨节点通信、矩阵广播和结果合并开销快速增大。SIMD 对上二对角化阶段有 1.26 倍收益, 但在 MPI+GKH 阶段几乎没有改善, 说明此时瓶颈已经由向量计算转向任务粒度和通信开销。本文据此给出基于实验数据的性能分析和后续改进方向。

关键词: SVD; MPI; Golub-Kahan; 任务池; SIMD; 性能分析

目录

1 实验目标与要求理解	1
1.1 选题要求	1
1.2 完成内容概述	1
2 算法与 MPI 并行设计	1
2.1 串行 SVD 流程	1
2.2 活动块并行粒度	1
2.3 主从式任务池	2
2.4 通信量设计	2
3 实现与代码分析	2
3.1 文件结构	2
3.2 矩阵连续内存接口	3
3.3 模式选择	3
3.4 任务分发与工作进程协议	3
3.5 结果打包与通信开销	4
3.6 统计字段与 profiling	4
4 实验方法	5
4.1 实验环境与数据采集	5
4.2 Profiling 设计	5
5 实验结果与分析	5
5.1 正确性验证	5
5.2 MPI 规模扩展	6
5.3 基于计时数据的开销分析	8
5.4 编译优化等级影响	8
5.5 SIMD 与 MPI 的组合	9
5.6 重复运行稳定性	10
5.7 本地 VTune 热点 profiling	11

6 进阶要求探索	12
6.1 不同平台与并行形态对比	12
6.2 不同 MPI 编程方法的比较	14
6.3 其他算法优化策略	15
7 综合讨论	15
7.1 为什么 $np = 4$ 最优	15
7.2 MPI 任务池的价值与限制	15
7.3 与前序 SIMD 实验的关系	15
8 总结	16
附录 A: 生成式 AI 辅助学习对话记录	17

1 实验目标与要求理解

1.1 选题要求

SVD 章节指出，多进程版本的难点在于：各进程地址空间独立，矩阵拷贝和通信开销很大，结果合并时竞争更严重，

手册对 SVD 提出了三个重点：第一，实现主从式结构，至少完成一个任务池；第二，围绕子矩阵或活动块组织迭代，避免已经收敛的 1×1 子问题反复参与计算；第三，完成加速和 profiling。

1.2 完成内容概述

本次实验在上一次 SVD 代码基础上完成如下工作：

- 在 `matrix.h` 中增加连续内存访问接口，使 MPI 能够广播矩阵数据。
- 在 `gkh.cpp` 中加入 `SVD_USE_MPI` 条件编译路径；使用 MPI 编译时，GKH 阶段默认进入 MPI 任务池模式。
- 设计 0 号进程调度、其他进程工作领取的主从式活动块任务池。只将长度大于 1 的非平凡活动块放入任务池，已经收敛的 1×1 块不再生成计算任务。
- 继承前序实验中的 SIMD 优化路径，并通过 `-DSVD_DISABLE_SIMD` 做对比实验。

2 算法与 MPI 并行设计

2.1 串行 SVD 流程

程序对 $m \times n$ 矩阵 A 计算 SVD。第一阶段使用左右 Householder 变换将矩阵化为上二对角矩阵：

$$A = UBV^T.$$

第二阶段在上二对角矩阵 B 上执行 Golub-Kahan 迭代，通过 Wilkinson shift 和 Givens 旋转进行 bulge chasing，使超对角元素逐步收敛到 0。最后程序将奇异值调整为非负并降序排列，得到标准化的 S 矩阵。该流程来自经典 SVD 算法 [1, 2]。

2.2 活动块并行粒度

GKH 迭代中，如果某个超对角元素已经足够接近 0，则上二对角矩阵可以被切分为多个相互独立的活动块。一个活动块 $[l, r]$ 表示第 l 到第 r 个奇异值相关的子问题尚未收敛。不同活动块之间不共享 B 的子块，更新 U, V 时也只涉及不重叠的列区间，因此可以在同一轮中并行处理。

不过，普通随机矩阵通常会在较长时间内保持一个大的活动块。此时即便启动多个 MPI 进程，也只有一个块可以推进，其余进程只能等待。只有当 deflation 产生多个非平凡活动块，或者输入矩阵本身具有块结构时，活动块任务池才有足够并行度。因此本实验的核心问题不是“MPI 是否一定加速”，而是通过数据判断：在本框架的端到端 SVD 测试中，活动块并行度是否足以抵消通信和复制开销。

2.3 主从式任务池

本实现采用 0 号进程作为调度者，其他进程作为工作进程。根进程扫描当前上二对角矩阵，将非平凡活动块按工作量排序后放入任务池。若任务数为 0，说明 GKH 已收敛；若任务数为 1，则根进程直接串行执行，避免把完整矩阵广播给其他进程却没有可用并行度；若任务数大于 1，则根进程广播当前 U, B, V ，工作进程领取活动块并执行一轮 bulge chasing。

Algorithm 1 MPI-GKH 活动块任务池

Input: 当前 U, B, V ，最大迭代次数 max_iter ，容忍误差 tol

Output: 收敛后的 U, S, V

```

1: for  $iter = 1$  to  $\text{max\_iter}$  do
2:   0 号进程清理数值噪声，并按超对角元素切分活动块
3:   将长度大于 1 的非平凡活动块放入任务池
4:   if 任务池为空 then
5:     广播停止命令，进入最终标准化
6:   else if 任务池只有一个活动块 then
7:     0 号进程本地执行该活动块，其他进程等待下一轮命令
8:   else
9:     0 号进程广播当前  $U, B, V$ 
10:    工作进程领取活动块并执行一轮 bulge chasing
11:    工作进程回传  $B[l:r, l:r]$ 、 $U[:, l:r]$ 、 $V[:, l:r]$ 
12:    0 号进程合并互不重叠的局部结果
13:   end if
14: end for
15: 0 号进程将奇异值非负化并降序排序
  
```

该设计没有强行并行化单个活动块内部的 Givens 旋转序列，因为 bulge chasing 本身存在顺序依赖。实验也会看到，进程数超过活动块并行度后，更多 MPI 进程不会自动带来加速。

2.4 通信量设计

在需要并行分发任务的一轮中，根进程广播完整的 U, B, V ，使所有工作进程从一致状态开始。工作进程完成活动块后不回传完整矩阵，而只回传：

$$B[l:r, l:r], \quad U[:, l:r], \quad V[:, l:r].$$

若活动块长度为 k ，矩阵规模近似为 $n \times n$ ，回传 double 数量约为 $k^2 + 2nk$ 。当活动块较小时，该策略比回传完整矩阵明显更省；当只有一个大块时，本实现退回根进程串行处理，避免没有并行收益的全矩阵广播。

3 实现与代码分析

3.1 文件结构

表1 给出本次实验涉及的主要文件。本报告关注算法、代码结构、实验数据和分析。

文件	作用
<code>matrix.h</code>	矩阵存储与基础运算。本次增加 <code>data()</code> 和 <code>size()</code> , 用于 MPI 广播连续内存。
<code>bidiagonalization.cpp</code>	Householder 上二对角化, 保留前序 SIMD 优化。
<code>gkh.cpp</code>	Golub-Kahan 迭代。本次新增 MPI 活动块任务池, 并保留 <code>serial</code> 、 <code>pthread</code> 、 <code>OpenMP</code> 路径。
<code>qsub_mpi.sh</code>	按修正脚本说明提交 MPI 作业。

表 1: 实验主要文件

3.2 矩阵连续内存接口

MPI 的 `MPI_Bcast` 只能广播连续缓冲区, 因此原有矩阵类需要暴露底层连续数组。这里没有改变矩阵数据结构, 只是在 `matrix.h` 中增加访问接口:

```
1 double *data() { return data_.data(); }
2 const double *data() const { return data_.data(); }
3 int size() const { return rows_ * cols_; }
```

这一改动的作用比较基础, 但很关键。若仍然通过逐行发送或逐元素发送矩阵, MPI 通信次数会大幅增加, 且代码容易在 U, B, V 三个矩阵同步时出错。使用连续内存后, 矩阵广播只需要先广播维度, 再广播 `double` 数组:

```
1 int dims[2] = {M.rows(), M.cols()};
2 MPI_Bcast(dims, 2, MPI_INT, 0, MPI_COMM_WORLD);
3 MPI_Bcast(M.data(), M.size(), MPI_DOUBLE, 0, MPI_COMM_WORLD);
```

3.3 模式选择

MPI 模式选择放在 `gkh.cpp` 内部完成。程序读取环境变量 `SVD_MODE`; 如果显式设置为 `serial`、`pthread`、`openmp` 或 `mpi`, 则按指定模式运行; 若使用 `-DSVD_USE_MPI` 编译且没有设置环境变量, 则默认进入 MPI 路径。

```
1 #ifdef SVD_USE_MPI
2 return GkhMode::Mpi;
3 #else
4 return GkhMode::Pthread;
5 #endif
```

这样设计的好处是: 同一份 `main.cpp` 可以在普通 C++ 编译和 MPI 编译之间复用; 服务器上只需要改变编译命令, 而不需要改测试入口。MPI 初始化也采用延迟初始化: 当 GKH 第一次进入 MPI 路径时检查 `MPI_Initialized`, 若尚未初始化则由 `gkh.cpp` 调用 `MPI_Init`, 并通过 `atexit` 注册 `MPI_Finalize`。此外, 非 0 号进程会关闭 `std::cout`, 避免所有 rank 重复输出测试结果。

3.4 任务分发与工作进程协议

MPI 部分使用三类命令控制工作进程:

- `MPI_CMD_STOP`: GKH 已结束, 工作进程退出循环;
- `MPI_CMD_IDLE_SERIAL`: 本轮只有一个非平凡活动块, 由 0 号进程串行推进, 工作进程等待;
- `MPI_CMD_DISTRIBUTE`: 本轮存在多个活动块, 广播矩阵并分发任务。

根进程在任务池中按工作量从大到小排序活动块, 先给每个工作进程发送一个任务, 自己也处理一个任务。随后根进程使用 `MPI_ANY_SOURCE` 接收完成结果, 哪个进程先完成就继续给它分配下一个任务。这相当于 MPI 版的动态调度, 能够缓解活动块大小不均造成的负载不均。

```

1 MPI_Recv(header, 2, MPI_INT, MPI_ANY_SOURCE,
2         MPI_TAG_RESULT_HEADER, MPI_COMM_WORLD, &status);
3 const int worker = status.MPI_SOURCE;
4 ...
5 if (next_task < task_count) {
6     send_mpi_task(worker, tasks[next_task++]);
7 } else {
8     send_mpi_stop(worker);
9 }

```

这一协议也是后续实验结果的解释基础: 当 ready task 很少时, 动态调度没有足够任务可分, MPI 进程数再多也只能等待; 当 ready task 较多时, 任务池才有可能体现收益。

3.5 结果打包与通信开销

工作进程完成活动块 $[l, r]$ 后不回传完整矩阵, 而是把必要结果打包为一段连续数组。打包顺序为:

1. 活动块对应的 $B[l:r, l:r]$;
2. U 中第 l 到第 r 列;
3. V 中第 l 到第 r 列。

对于长度为 k 的活动块, 回传数据量为

$$k^2 + mk + nk$$

个 double。这比回传完整 U, B, V 小得多, 但前提是活动块足够小。另一方面, 每次进入并行分发轮次前, 根进程仍需广播完整 U, B, V , 这是当前实现最主要的通信成本。该设计是正确性优先的折中: 先保证所有工作进程从完全一致的矩阵状态出发, 再通过局部回传降低合并成本。后续若要继续优化, 最有价值的方向是减少广播范围, 例如只同步当前活动块相关列, 或让工作进程持有跨轮状态, 避免每轮全量同步。

3.6 统计字段与 profiling

`GkhRunStats` 中保留了迭代次数、活动块数量、可并行轮次、最大 ready task、MPI 任务发送数、矩阵广播字节数和结果回传字节数等字段。结合本次服务器数据, 可以确认主要瓶颈确实不在数值正确性, 而在活动块并行度与 MPI 通信开销的平衡。

4 实验方法

4.1 实验环境与数据采集

数据来自课程服务器，编译器使用 `mpic++`，MPI 头文件路径显示为 `mpich-aarch64`。任务通过 PBS 的 `qsub` 提交，每个计算节点最多申请 8 个核心，最多使用 4 个节点。

```
1 mpic++ -std=c++17 -O2 -DSVD_USE_MPI main.cpp bidiagonalization.cpp gkh.cpp -o
   main
2 qsub qsub_mpi.sh
```

实验固定随机种子为 2412592，采集了四类数据：MPI 规模扩展、编译优化等级、SIMD 开关、固定配置重复运行。所有结果均按类别保存为 `data/results/raw/**/test.o` 和 `test.e`，汇总表为 `data/results/summary.csv`。本报告基于 41 组有效运行数据进行统计，图中误差线为同组重复运行的标准差。

图表绘制使用 Python 对 `summary.csv` 做二次统计，并采用 `SciencePlots` 与 `Matplotlib` 生成。增加了误差线、关键点标注、堆叠时间构成和热力图汇总，便于直接观察最优进程数、负优化区间和不同优化手段的贡献。

MPI 初始化放在 `gkh.cpp` 的 GKH 入口中。每个 MPI 进程在进入 GKH 前都会执行一次主程序中的上二对角化阶段，`test.o` 中也会看到若干重复样例标题。真正的 MPI 并行优化对象是 GKH 阶段，所以本文在讨论规模扩展时以 GKH 时间为主，同时保留端到端总时间作为参考。

4.2 Profiling 设计

本文采用“服务器计时数据 + 本地热点采样”的方式完成分析。服务器端主要依据 41 组真实 PBS 运行输出中的上二对角化时间、GKH 时间、不同进程数下的均值和标准差。这样可以直接观察 MPI 进程数增加后，通信、复制、等待和任务粒度对端到端时间的影响。作为补充，本地使用 Intel VTune 对 `main.cpp` 单进程入口做热点采样，用来判断子进程内部主要计算热点。

5 实验结果与分析

5.1 正确性验证

41 组数据全部显示通过：5 / 5，未出现 FAIL 或 `converged: no`。所有测试样例中，最大相对重构误差为 4.80×10^{-13} ，最大 U 正交误差为 2.35×10^{-13} ，最大 V 正交误差为 2.38×10^{-13} 。这说明 MPI 任务分发、局部结果合并和 SIMD 开关都没有破坏 SVD 数值正确性。

指标	最大值	典型量级	结论
相对重构误差 $\ A - USV^T\ _F / (\ A\ _F + 1)$	4.80×10^{-13}	10^{-13}	通过
$\ U^T U - I\ _F$	2.35×10^{-13}	10^{-13}	通过
$\ V^T V - I\ _F$	2.38×10^{-13}	10^{-13}	通过
通过样例数	5/5	所有 41 组	通过

表 2: 正确性实验摘要

5.2 MPI 规模扩展

表3 与图1 展示了不同进程数下的平均耗时。GKH 阶段在 $np = 4$ 时达到本组实验最好结果，平均耗时为 15975.63 ms，相对 $np = 1$ 的 23147.60 ms 加速 1.45 倍；但是 $np = 8$ 时回升至 17322.33 ms， $np = 16$ 时进一步回升至 19177.90 ms， $np = 32$ 时显著退化为 67490.93 ms。端到端总时间的最优点同样出现在 $np = 4$ ，为 22707.15 ms，相对 $np = 1$ 的 27481.56 ms 加速 1.21 倍。

np	nodes	ppn	上二对角/ms	GKH/ms	总时间/ms	GKH 加速比	GKH 效率
1	1	1	4333.96	23147.60	27481.56	1.00	100.0%
2	1	2	6080.27	22535.20	28615.47	1.03	51.4%
4	1	4	6731.51	15975.63	22707.15	1.45	36.2%
8	1	8	8795.52	17322.33	26117.86	1.34	16.7%
16	2	8	9580.87	19177.90	28758.77	1.21	7.5%
32	4	8	9400.84	67490.93	76891.77	0.34	1.1%

表 3: MPI 规模扩展实验平均结果，固定种子 2412592，每组 3 次




图 1: MPI 规模扩展：上二对角化与 GKH 平均耗时




图 2: MPI 规模扩展：加速比与并行效率

图3 用热力图汇总了同一组数据。所有行均为“越高越好”的指标，可以直观看出 $np = 4$ 同时具有最高 GKH 加速比和最高端到端加速比，而 $np = 32$ 在所有性能指标上都明显退化。尤其是 GKH 并行效率从 $np = 4$ 的 36.2% 下降到 $np = 8$ 的 16.7%、 $np = 16$ 的 7.5%，到 $np = 32$ 只剩 1.1%。这表明瓶颈不是计算核心数量不足，而是可以被分发的有效任务太少。




图 3: 规模扩展关键指标热力图

该结果说明，当前端到端随机矩阵测试中的可用活动块数量不足以支撑大量 MPI 进程。 $np = 2$ 只有 1.03 倍 GKH 加速，说明任务池已经被同步和调度开销明显抵消； $np = 4$ 是较平衡点，仍在单节点内，通信成本较低； $np = 16$ 进入跨节点后，广播 U, B, V 和回收局部结果的代价上升； $np = 32$ 虽满足脚本上限，但进程数远大于可同时处理的活动块数量，通信和等待成为主要开销，因此出现负优化。这也与实验手册中“大于 32 进程后通信时间会显著增长、加速意义不明显”的提示一致。

从数据波动看， $np = 32$ 的 GKH 标准差约为 36.5 秒，明显高于其他组。这说明进程数过多不只是平均速度变慢，也会让运行稳定性变差。原因可能包括跨节点分配差异、每轮广播矩阵时网络状态变化，以及少量活动块在 32 个进程之间造成更严重的等待放大。相比之下， $np = 4$ 的 GKH 标准差约为 4.5 秒，虽然仍受服务器负载影响，但整体更加可控。

图4 从端到端角度展示了时间构成。上二对角化没有被 MPI 分布式化，且会在各 rank 中重复执行，因此它并不随 np 增加而下降，反而可能因为多进程同时运行和节点负载变化而波动。即便如此，GKH 仍然占主要部分，说明将优化重点放在 GKH 阶段是合理的。也正因为上二对

角化不是本次 MPI 优化对象，本文在判断并行策略时优先观察 GKH 时间和 GKH 加速比，而把端到端时间作为整体工程代价。




图 4: 端到端时间构成

5.3 基于计时数据的开销分析

对 1000×1000 主测试样例而言, U, B, V 三个矩阵各约含 10^6 个 `double`, 单矩阵约 8 MB, 三者合计约 24 MB。由于 MPI 进程内存空间相互独立, 每个 rank 都需要持有自己的矩阵副本; 当进入并行分发轮次时, 根进程还需要广播当前 U, B, V , 这正是多进程 SVD 比多线程更难加速的核心原因之一。

结果回传虽然只传活动块相关数据, 长度为 k 的活动块回传量约为 $k^2 + mk + nk$ 个 `double`, 比完整矩阵小得多, 但这种优化只有在活动块已经切分得比较小时才明显有效。如果迭代中长期只有一个大的非 1×1 活动块, 任务池没有足够任务可分, 程序会退回 0 号进程串行推进; 如果强行让所有 worker 参与, 则每轮广播 24 MB 级矩阵却只能处理少量有效任务, 通信与复制成本会盖过计算收益。

表3 给出了这一现象的数据证据: $np = 4$ 时 GKH 平均时间为 15975.63 ms, 取得 1.45 倍 GKH 加速; 继续增至 $np = 8$ 后, GKH 时间回升到 17322.33 ms; 跨节点 $np = 16$ 为 19177.90 ms; $np = 32$ 更退化到 67490.93 ms。若瓶颈只是计算量不足, 增加进程数至少不应导致如此明显的退化; 实际结果说明, 复制、广播、结果合并和进程等待已经成为主要开销。 $np = 32$ 的 GKH 标准差约 36.5 秒, 也说明高进程数下性能不仅更慢, 而且更不稳定。

因此, 本文的 profiling 结论是: 当前实现中真正有收益的是中等进程数下对多个活动块的动态调度; 当活动块数量不足或跨节点通信放大时, 进程独立内存和全量矩阵同步会迅速抵消收益。

5.4 编译优化等级影响

表4 和图5 比较了 -O0、-O1、-O2、-O3。在固定 $np = 8$ 和启用 SIMD 的情况下, -O0 总时间为 121703.03 ms; -O1、-O2、-O3 均将总时间降到约 25 秒, 其中 -O2 最快, 总加速比为 4.82。

优化等级	上二对角/ms	GKH/ms	总时间/ms	相对 O0 加速比
-00	26995.80	94707.23	121703.03	1.00
-01	6727.19	19179.70	25906.89	4.70
-02	6203.41	19043.00	25246.41	4.82
-03	6030.14	19347.33	25377.48	4.80


表 4: 编译优化等级实验, 固定 $np = 8$ 、SIMD、种子 2412592, 每组 3 次

图 5: 编译优化等级对端到端耗时的影响

优化等级实验说明, 编译器优化是本程序的基础性能条件。没有优化时, GKH 中大量循环、Givens 旋转和矩阵列更新会产生巨大开销; 开启 -01 后大部分收益已经出现, GKH 时间从 94707.23 ms 降到 19179.70 ms, 约为原来的 20.3%。-02 相比 -01 只继续减少约 3.5% 的总时间, -03 反而略慢于 -02。这说明当前瓶颈并不只是单核浮点计算, 调度、通信和内存访问也在限制性能。

这组数据还提醒我们不能把编译器优化收益误认为 MPI 收益。如果把 -00 的结果和 -02 的 MPI 结果直接比较, 会得到非常大的“加速比”, 但那主要来自编译器优化而不是并行任务池。因此后续规模扩展和 SIMD 对比均固定在 -02 下进行。

5.5 SIMD 与 MPI 的组合

表5 和图6 给出 SIMD 开关对比。启用 SIMD 后, 上二对角化平均耗时从 10367.03 ms 降至 8232.26 ms, 加速约 1.26 倍; 但 GKH 平均耗时从 20227.73 ms 变为 20337.07 ms, 几乎没有提升, 甚至略慢; 总时间加速约 1.07 倍。

SIMD 设置	上二对角/ms	GKH/ms	总时间/ms	总时间标准差/ms
启用 SIMD	8232.26	20337.07	28569.33	2922.36
禁用 SIMD	10367.03	20227.73	30594.76	2553.58

表 5: SIMD 开关对比, 固定 $np = 8$ 、-02、种子 2412592, 每组 3 次




图 6: SIMD 开关对比

这组数据说明：MPI+SIMD 不一定优于只优化 SIMD，也不一定让 GKH 阶段明显变快。SIMD 主要加速连续向量运算，例如范数、点积和批量列更新；而本次 MPI-GKH 中，普通随机矩阵的瓶颈更多来自活动块并行度不足、矩阵广播、进程等待和结果合并。上二对角化阶段有较多连续向量计算，所以启用 SIMD 后从 10367.03 ms 降到 8232.26 ms；GKH 阶段虽然也有局部向量更新，但每轮还包含活动块扫描、shift 计算、Givens 参数生成和 MPI 同步，SIMD 覆盖比例较低，因此 20337.07 ms 与禁用 SIMD 的 20227.73 ms 基本处于实验波动范围内。

换言之，SIMD 优化提高的是单进程局部计算效率，而 MPI 任务池解决的是活动块级任务分发。两者不是简单相乘关系：当任务粒度足够大且通信相对较少时，SIMD 与 MPI 可以叠加；当通信和等待占主导时，SIMD 的局部收益会被更高层的并行开销吞没。

5.6 重复运行稳定性

为避免单次测量受队列状态和节点负载影响，固定 -O2+SIMD、 $np = 8$ 、种子 2412592 额外重复运行 5 次。结果见表6 和图7。总时间均值为 26476.07 ms，标准差为 2110.68 ms，变异系数为 8.0%；GKH 变异系数为 9.3%。

重复次数	上二对角/ms	GKH/ms	总时间变异系数
5	6673.45 ± 1354.86	19802.62 ± 1831.75	8.0%

表 6: 固定配置重复实验，-O2+SIMD、 $np = 8$ 、种子 2412592




图 7: 固定配置重复运行的总时间波动

这说明服务器实验存在一定运行波动，尤其是 MPI 作业会受到节点分配、队列负载和跨节点通信状态影响。因此本文对规模扩展、优化等级和 SIMD 开关均使用多次重复的平均值，而不是选择单次最优结果。固定 $np = 8$ 的重复实验中，总时间变异系数为 8.0%，GKH 时间变异系数为 9.3%，属于可以接受但不能忽略的波动范围。该处理也解释了部分表格中标准差较大的现象，例如 $np = 32$ 的 GKH 标准差达到约 36.5 秒，说明过多进程不仅平均性能差，稳定性也更差。

因此，在评价本实验时，更有意义的不是某一次运行是否偶然较快，而是多次平均后是否呈现稳定趋势。规模扩展实验的趋势非常清楚：从 $np = 1$ 到 $np = 4$ 有有限加速，从 $np = 8$ 开始收益下降，跨节点和高进程数下出现负优化。这一趋势与 SVD-GKH 活动块并行度有限的算法分析相一致。

5.7 本地 VTune 热点 profiling

在本地 Windows 环境中，使用 VTune 对 -O2、启用 SIMD、固定种子 2412592 的 `main.cpp` 单进程运行进行热点采样。该 profiling 不用于替代服务器 MPI 实验，因为它没有跨进程通信；它的作用是回答“每个进程内部主要把 CPU 时间花在哪里”。本地运行 5 个样例全部通过，最大规模 1000x1000 样例中，上二对角化耗时 1935.63 ms，GKH 耗时 4129.38 ms，总 GKH 耗时 4239.91 ms。

热点函数	CPU 时间/s	占比	解释
<code>apply_right_cols_range</code>	2.689	36.3%	GKH 中对列区间应用右乘 Givens 更新
<code>Matrix::operator*</code>	1.405	18.9%	<code>main.cpp</code> 正确性验证中的矩阵重构乘法
<code>cleanup_bidiagonal</code>	0.618	8.3%	清理近零超对角元并划分活动块
<code>_mm_add_pd</code>	0.400	5.4%	SIMD 双精度加法指令
<code>_mm_loadu_pd</code>	0.354	4.8%	SIMD 非对齐加载指令
<code>simd_dot</code>	0.275	3.7%	上二对角化中的向量点积

表 7: 本地 VTune hotspots 结果，官方 `main.cpp` 单进程运行




图 8: 本地 VTune 热点函数占比

表7和图8表明,子进程内部最主要的热点是 GKH 的列区间更新函数 `apply_right_cols_range`, 占 CPU 时间 36.3%。这与算法分析一致: bulge chasing 每一步都需要对 B 和 V 的相关列做 Givens 旋转, 虽然局部操作可以被 SIMD 化, 但访问模式和迭代依赖仍然决定了它是 GKH 的主要计算核。第二个热点 `Matrix::operator*` 来自 `main.cpp` 中的正确性验证, 即计算 USV^T 的重构误差; 它不属于被优化的 GKH 算法本体, 但会出现在端到端时间和本地 profiling 中。

这一结果可以解释 SIMD 实验中的现象: VTune 的热点表中确实出现了 `_mm_add_pd`、`_mm_loadu_pd`、`simd_dot` 等 SIMD 相关项, 说明向量化代码被执行; 但是在 MPI+GKH 场景中, 活动块划分、清理、矩阵同步和任务等待共同参与耗时, 所以 SIMD 指令热点并不能直接转化为 GKH 阶段的线性加速。也就是说, 子进程内部仍有计算热点可优化, 但服务器规模扩展曲线的主要限制已经上升到活动块并行度和 MPI 通信层面。

6 进阶要求探索

6.1 不同平台与并行形态对比

本实验主要运行平台是课程服务器, 编译环境显示 MPI 头文件来自 `mpich-aarch64`, 因此服务器数据可视为 ARM 平台上的 MPI+SIMD 实验。作为对照, 本地 Windows x86 环境中保留了 serial、pthread 与 VTune profiling 数据。两类平台的 CPU、编译器、系统负载和矩阵规模并不完全一致, 所以本文不把它们绝对耗时直接横向比较, 而只比较“同一平台、同一输入内部”的加速趋势。

平台	并行形态	代表样例	GKH/ms	加速比	可并行轮次
x86 本地	serial+SIMD	随机 512×512	4421.59	1.00	—
x86 本地	pthread4+SIMD	随机 512×512	4402.29	1.00	8/749
x86 本地	OpenMP4+SIMD	随机 512×512	4385.86	1.01	8/749
x86 本地	serial+SIMD	4 个 128 块	1130.35	1.00	—
x86 本地	pthread4+SIMD	4 个 128 块	360.63	3.13	252/253
x86 本地	OpenMP4+SIMD	4 个 128 块	359.08	3.15	252/253
ARM 服务器	MPI+SIMD, $np = 1$	随机 1000×1000	23147.60	1.00	未输出
ARM 服务器	MPI+SIMD, $np = 4$	随机 1000×1000	15975.63	1.45	未输出
ARM 服务器	MPI+SIMD, $np = 32$	随机 1000×1000	67490.93	0.34	未输出

表 8: 不同平台和并行形态的实测数据对比




图 9: 不同平台与并行形态的相对加速趋势

本地补充实测在 Windows x86_64 环境中完成, 编译器为 MinGW-W64 g++ 7.3.0。这组实验不用于和 ARM 服务器做绝对耗时排名, 而是固定同一平台、同一输入, 比较 serial、pthread4 与 OpenMP4 在活动块并行度不同的情况下能否加速。OpenMP4 版本的编译与运行命令如下, 随机种子固定为 20260408:

```

1 g++ -std=c++17 -O2 -fopenmp experiment_driver.cpp \
2     bidiagonalization.cpp gkh.cpp \
3     -o profiling/experiment_openmp.exe
4
5 $env:SVD_MODE='openmp'
6 $env:SVD_THREADS='4'
7 .\profiling\experiment_openmp.exe --seed 20260408 --repeat 1 \
8     --sizes 512x512 --gkh-blocks 128x4

```

实测输出中两个样例均为 PASS。随机 512×512 的相对重构误差为 3.7935×10^{-13} , OpenMP4 的 GKH 时间为 4385.86 ms; 4 个 128 块结构样例的相对重构误差为 3.8720×10^{-13} , OpenMP4 的 GKH 时间为 359.08 ms。与同一输入下的 serial 和 pthread4 数据放在一起可以看到: 随机矩阵中 OpenMP4 只比 serial 快约 1.01 倍, 而块结构中 OpenMP4 可达到 3.15 倍。这说明本地实测的核心变量不是“线程 API 名称”, 而是活动块是否真的提供了足够的并行任务。

Advanced experiments: parallel opportunity evidence




图 10: 活动块并行机会与工作量不均衡

表8、图9 和图10 的关键结论是: 平台差异不是唯一决定因素, 活动块并行度更直接决定了并行收益。本地 x86 上, 随机 512×512 的可并行轮次只有 8/749, pthread4 和 OpenMP4 的 GKH

加速比分别只有 1.00 和 1.01；同时 active worker 的最大/最小工作量比例约为 $2.23 \times 10^6 : 1$ ，说明几乎所有实质工作仍集中在一个 worker 上。相反，4 个 128 块样例中可并行轮次为 252/253，最大/最小工作量比例仅约 1.08 : 1，pthread4 和 OpenMP4 分别达到 3.13 和 3.15 倍加速。ARM 服务器上也呈现类似趋势：当 $np = 4$ 仍能承接一定活动块时，MPI+SIMD 有有限收益；当 $np = 32$ 远大于可同时处理的活动块数量时，通信和等待开销超过计算收益，性能显著退化。

这组进阶对比说明，多线程、SIMD 和 MPI 的关系不是简单叠加。SIMD 改善单个 rank 或线程内部的向量运算，多线程和 MPI 需要足够多的独立任务才能发挥作用。若算法长期只有一个大活动块，换成更多线程、更多进程或更强平台都难以自动获得线性加速。

6.2 不同 MPI 编程方法的比较

本次最终代码采用阻塞双边通信：根进程通过 MPI_Bcast 同步矩阵状态，通过 MPI_Send/MPI_Recv 下发任务和回收结果，并使用 MPI_ANY_SOURCE 实现动态任务领取。选择该方案的原因是它最容易保证 GKH 每轮矩阵状态一致，也便于定位正确性问题。表9 总结了可选 MPI 编程方法在本 SVD-GKH 场景中的适用性。

方法	适用点	可能收益	主要风险
阻塞双边通信	已在最终代码中实现，任务和结果顺序清晰	正确性最稳定，便于统计广播与回传开销	根进程等待明显，通信与计算重叠少
非阻塞双边通信	可将 MPI_Isend/MPI_Irecv 用于任务下发和结果回收	当 ready task 很多时，有机会隐藏部分结果回传延迟	GKH 下一轮依赖合并后的矩阵状态，普通随机矩阵中可重叠空间有限
单边通信 RMA	可尝试用 MPI_Win 暴露活动块缓冲区，由 worker 主动读写	理论上减少根进程参与频率，适合固定缓冲区反复复用	一致性、锁和窗口同步复杂； U, V 列更新不连续，容易引入合并错误
MPI 自身多线程支持	可用 MPI_Init_thread 组成 MPI+pthread 混合模型	一节点一个或少量 rank，rank 内用线程，可减少跨进程矩阵复制	MPI_THREAD_MULTIPLE 可能带来额外锁开销；需要严格限定通信线程

表 9: 不同 MPI 编程方法在 SVD-GKH 中的适用性分析

np	每轮完整 $U + B + V$ 广播量/MB	GKH 平均耗时/ms	GKH 加速比
1	0	23147.60	1.00
2	24	22535.20	1.03
4	72	15975.63	1.45
8	168	17322.33	1.34
16	360	19177.90	1.21
32	744	67490.93	0.34

表 10: 阻塞 MPI 方案的通信量估算与实测性能

从当前 41 组服务器数据和表10 看，最值得继续尝试的不是盲目引入更复杂的通信模型，而是混合并行：节点间使用较少 MPI rank，节点内复用已有 pthread/OpenMP 活动块任务池。对 1000×1000 主样例， U, B, V 三个矩阵合计约 24 MB；当前阻塞方案每次进入分发轮次都要向 $world_size - 1$ 个 worker 广播完整矩阵，因此 $np = 32$ 时单轮广播量估计达到 744 MB。非阻

塞通信可以隐藏一部分发送/接收等待，但不能减少这部分数据量；单边通信也仍需处理同样的矩阵一致性问题。结合图10 中随机矩阵只有 1.07% 的可并行轮次，非阻塞和单边通信在普通随机矩阵上能重叠的计算窗口很小，更适合作为有块结构输入或混合并行方案上的后续优化分支。

6.3 其他算法优化策略

除通信方式外，本实验还可以从算法层面继续优化。第一，设置任务粒度阈值：当活动块数量少或块太小时，直接在根进程串行推进，避免广播完整矩阵。当前实现已经包含“只有一个非平凡块时串行推进”的思想，后续可把阈值从数量扩展到估算工作量。第二，减少同步数据量：不要每轮广播完整 U, B, V ，而是只同步与活动块相关的 B 子块和 U, V 列区间；这一策略能够直接降低表9 中阻塞通信的主要开销。第三，延迟更新正交矩阵：先记录 Givens 旋转序列，待若干轮后批量更新 U, V ，可能提升缓存局部性和 SIMD 覆盖率，但需要额外验证重构误差和数值稳定性。第四，构造并识别块结构输入：本地 x86 的 4 块样例说明，只要活动块数量充足，已有任务池就能取得明显收益；因此对具有块结构或近似块对角结构的矩阵，MPI 任务池更可能发挥作用。

7 综合讨论

7.1 为什么 $np = 4$ 最优

从实验结果看， $np = 4$ 是当前实现和测试数据上的最佳折中。它仍然位于单节点内，通信主要是节点内 MPI 通信，广播和回收开销较低；同时相比 $np = 1$ 和 $np = 2$ ，它又有足够进程承接 deflation 后出现的多个活动块。继续增加到 $np = 8$ 后，并行度增长已经赶不上调度和等待成本；跨节点的 $np = 16$ 、 $np = 32$ 则进一步放大了数据复制和通信开销。

这说明本实验的性能瓶颈不是“没有 MPI”，而是 SVD-GKH 本身很难在普通随机矩阵上长期提供大量独立任务。实验手册中的特殊情况说明也指出，迭代中可能长期只有一个非 1×1 大矩阵，其余矩阵都已经收敛；本实验的规模扩展曲线正体现了这一性质。

7.2 MPI 任务池的价值与限制

任务池的价值在于正确处理了负载不均衡问题：当多个活动块存在时，工作进程不是静态绑定某个块，而是空闲后继续领取任务。这比固定块划分更适合 GKH 中块大小不断变化的过程。但任务池不能创造算法并行度。如果某一轮只有一个大活动块，根进程串行推进反而是更优选择，因为强行广播完整矩阵只会增加开销。

因此，当前实现对“块数量足够”的场景是有效的，对普通随机矩阵只能获得有限收益。后续如果要进一步优化，可以考虑两条方向：一是寻找活动块内部更细粒度但数学上安全的并行更新；二是减少广播量，例如只同步与当前活动块相关的矩阵列，或在多轮任务之间复用工作进程状态，避免每次都广播完整 U, B, V 。

7.3 与前序 SIMD 实验的关系

SIMD 优化仍然是必要的基础优化。它对上二对角化阶段有稳定收益，并能降低局部向量运算成本。但在 MPI-GKH 中，SIMD 无法解决进程等待、活动块数量不足和通信放大问题。因此不能简单地说“MPI+SIMD 一定最快”。更准确的结论是：SIMD 提高单进程计算核效率，MPI 提供跨进程任务调度能力；只有当任务粒度足够大、通信足够少、活动块足够多时，二者叠加才可能得到明显收益。

8 总结

本次实验完成了 SVD 算子的 MPI 并行化实现和服务端实验验证。代码层面将 MPI 初始化和任务池逻辑封装在 `gkh.cpp` 中；实验流程层面按照修正脚本说明，使用 `mpic++` 编译和 `qsub_mpi.sh` 提交。

从 41 组真实服务器数据看，程序正确性稳定，全部测试通过，误差保持在 10^{-13} 量级。性能方面，GKH 阶段在 $np = 4$ 时取得最好平均结果，加速比为 1.45； $np = 8$ 后收益下降， $np = 32$ 出现明显负优化。编译优化对性能影响显著，-O2 相比 -O0 端到端加速 4.82 倍；SIMD 对上二对角化有 1.26 倍收益，但对 MPI-GKH 基本无提升。综合来看，SVD 的 MPI 加速受活动块并行度强烈限制，任务池实现是必要的，但通信和算法粒度决定了其上限。

进阶探索部分进一步对比了 ARM 服务器 MPI+SIMD 与本地 x86 pthread/OpenMP+SIMD 的趋势。结果表明，随机矩阵的可并行轮次只有 8/749，pthread4 和 OpenMP4 都只能获得约 1.0 倍 GKH 加速；人工块结构样例的可并行轮次达到 252/253，pthread4 与 OpenMP4 分别达到 3.13 和 3.15 倍 GKH 加速。MPI 通信量估算也显示， $np = 32$ 时完整 $U + B + V$ 广播量每轮可达约 744 MB。这说明后续优化的重点应放在减少通信复制、提高活动块并行度以及发展 MPI+ 线程的混合并行，而不是单纯增加进程数。

附录 A：生成式 AI 辅助学习对话记录

本附录记录了实验过程中利用生成式 AI 辅助理解 SIMD、多线程和 MPI 编程的对话截图。提问方式遵循“先给出自己的实现、实验数据或瓶颈判断，再请求 AI 检查和分析”的原则，避免直接要求 AI 代写完整代码或编造实验结论。



图 11: AI 辅助学习对话记录 1




图 12: AI 辅助学习对话记录 2



图 13: AI 辅助学习对话记录 3




图 14: AI 辅助学习对话记录 4

参考文献

- [1] Gene H. Golub and William Kahan. Calculating the singular values and pseudo-inverse of a matrix. *Journal of the Society for Industrial and Applied Mathematics, Series B: Numerical Analysis*, 2(2):205–224, 1965.
- [2] Gene H. Golub and Christian Reinsch. Singular value decomposition and least squares solutions. *Numerische Mathematik*, 14:403–420, 1970.